

Universidade Estadual de Campinas
Instituto de Computação

MO434 — Projeto Final

Estudo Comparativo de Esquemas de Destilação de Conhecimento Baseados em Características Latentes de Classificadores Pré-treinados

Rafael Attilio Agricola
RA: 249245

Julho de 2026

Resumo

Este trabalho apresenta um estudo comparativo sobre a eficácia de abordagens de Destilação de Conhecimento Baseada em Características (*Feature-based Knowledge Distillation*) aplicadas a redes neurais convolucionais leves voltadas para dispositivos de borda. O objetivo central consiste em forçar arquiteturas compactas (MobileNetV2 com fator de largura comprimido e ShuffleNetV2) a mimetizarem as representações latentes geradas logo após a camada de agrupamento espacial global (*post-GAP*) de três famílias de classificadores de grande porte pré-treinados no ImageNet: VGG, ResNet e ConvNeXt. O pipeline experimental estruturou-se em duas etapas consecutivas: a sondagem linear (*linear probing*) dos extratores dos professores com backbones inteiramente congelados e a destilação dos estudantes via regressão por Erro Quadrático Médio (MSE) assistida por um módulo projetor multicamadas. As avaliações quantitativas foram conduzidas nos conjuntos de dados CIFAR-100 e Intel Scenes. Os resultados empíricos expõem fenômenos contra-intuitivos fundamentais da transferência de conhecimento, incluindo o colapso do aprendizado devido ao estrangulamento geométrico de posto e capacidade latente (*capacity mismatch*), ou a saturação de manifolds em tarefas de baixa complexidade.

Palavras-chave: Destilação de Conhecimento, Classificadores Pré-treinados, Linear Probing, Post-GAP, Alinhamento de Manifolds.

1 Introdução e Fundamentação Teórica

Os avanços na área de reconhecimento de imagens consolidaram o uso de arquiteturas profundas e massivamente parametrizadas como VGG [Simonyan e Zisserman 2014], ResNet [He et al. 2016] e ConvNeXt [Liu et al. 2022]. Embora a geração atual de modelos demonstre capacidades extraordinárias de extração de características geométricas, suas demandas computacionais em termos de memória e operações de ponto flutuante inviabilizam sua implantação direta em cenários de computação de ponta (*edge computing*).

Como alternativa, a técnica de Destilação de Conhecimento (Hinton et al. [Hinton, Vinyals e Dean 2015]), propõe transferir o conhecimento absorvido por um modelo complexo (“Professor”) para uma rede significativamente menor (“Estudante”). Enquanto as formulações clássicas se concentram no pareamento de *logits* suavizados por uma temperatura suave, abordagens modernas como os FitNets de Romero et al. [Romero et al. 2014] demonstraram que o alinhamento de representações latentes intermediárias fornece um sinal de supervisão muito mais rico, agindo como guias para o aprendizado do estudante.

Este projeto adota uma variante focada na destilação de representações pós-agrupamento global (*pooled-output / post-GAP representation distillation*). Diferente de métodos que distorcem o conhecimento prévio por meio do ajuste fino completo do extrator, o escopo deste trabalho impõe que o conhecimento pré-treinado no ImageNet seja preservado de forma estritamente intacta. Assim, o professor atua como um gerador estático de *manifolds* de alta dimensão, cabendo ao estudante aproximar essa topologia latente por meio de um mapeamento de regressão de características.

2 Metodologia e Implementação do Pipeline

O pipeline experimental foi segmentado em duas fases bem definidas, executadas de forma paralela e assíncrona através de uma arquitetura baseada em filas (*JoinableQueue*) distribuídas entre múltiplos aceleradores de hardware (GPUs).

2.1 Fase 1: Sondagem Linear dos Professores

Para avaliar e fixar a capacidade extratora dos professores, dez arquiteturas foram selecionadas e inicializadas com pesos do ImageNet: VGG (11, 16 e 19 com camadas de *Batch Normalization*), ResNet (18, 50 e 101) e ConvNeXt (Tiny, Small, Base e Large). O bloco extrator de cada rede foi congelado na sua totalidade ($\nabla_{\theta_{\text{backbone}}} = 0$). O treinamento restringiu-se ao ajuste adaptativo de uma camada linear de classificação conectada à saída da camada de *Global Average Pooling* (GAP). Essa abordagem garante que os vetores de características avaliados na fase subsequente sejam projeções puras e inalteradas do conhecimento original do ImageNet.

2.2 Fase 2: Destilação baseada em Características

Na fase de destilação, foram avaliados dois modelos estudantes altamente eficientes: a MobileNetV2 (configurada com multiplicador de largura `width_mult=0.5` para maximizar a compressão) e a ShuffleNetV2. O classificador padrão dessas redes foi descartado por meio de uma operação de identidade (`nn.Identity()`).

Como a dimensionalidade nativa de saída do extrator do estudante (1280 canais no caso da MobileNetV2 e 1024 canais na ShuffleNetV2) raramente coincide com a dimensionalidade do vetor *post-GAP* do professor, projetou-se um módulo preditor denso multicamadas (*MLP Predictor*)

acoplado ao estudante, definido estruturalmente conforme a Equação 1:

$$P(z) = W_2 \cdot \text{ReLU}(\text{BN}(W_1 \cdot z)) \quad (1)$$

Onde W_1 projeta as características do estudante para uma camada oculta fixa com 512 neurônios, seguida por uma camada de *Batch Normalization* (BN) e uma ativação não-linear ReLU. Por fim, W_2 mapeia o vetor intermediário para a dimensão exata do vetor alvo do professor (D_{prof}), permitindo o cálculo do objetivo de otimização combinada (Equação 2):

$$\mathcal{L} = \alpha \cdot \mathcal{L}_{\text{MSE}}(P(z_{\text{est}}), z_{\text{prof}}) + \beta \cdot \mathcal{L}_{\text{CE}}(C_{\text{prof}}(P(z_{\text{est}})), y) \quad (2)$$

Aqui, $\mathcal{L}_{\text{MSE}}$ representa o erro quadrático médio de regressão latente e $\mathcal{L}_{\text{CE}}$ é a perda de entropia cruzada obtida ao passar a característica prevista do estudante pelo próprio classificador linear já treinado do professor (C_{prof}). Para os experimentos, os hiperparâmetros foram fixados em $\alpha = 1.0$ e $\beta = 1.0$. Todas as imagens de entrada foram redimensionadas e normalizadas uniformemente para a resolução padrão de 224×224 pixels.

3 Dificuldades Encontradas e Otimizações

O percurso experimental impôs desafios metodológicos substanciais associados à dinâmica de convergência e à estabilidade do treinamento dos classificadores e do processo de destilação. Afastando-se de limitações estritas de infraestrutura computacional, as principais dificuldades científicas centraram-se em nuances empíricas do aprendizado profundo, detalhadas a seguir:

1. **Sensibilidade e Estabilização via Tamanho do Lote (*Batch Size*):** Durante as etapas iniciais do pipeline, observou-se uma severa instabilidade e oscilação nas curvas de acurácia de validação quando utilizados lotes pequenos ou moderados. Para mitigar esse comportamento, foram conduzidos testes sistemáticos variando o tamanho do lote entre 128, 256 e 512 amostras. A análise comparativa revelou que regimes de menor dimensionalidade amostral induziam um ruído excessivo nas estimativas de gradiente do classificador linear. Dentre os três valores testados, a seleção definitiva do `batch_size = 512` justificou-se matematicamente por amortecer tais flutuações em ambos os conjuntos de dados.




Figura 1: Acurácia da ConvNext-Large com Batch de 128 (cifar 100)




Figura 2: Acurácia da ConvNext-Large com Batch de 512 (cifar 100)

2. **Instabilidade Crônica de Convergência na Família VGG:** Mesmo sob o cenário otimizado com o tamanho de lote fixado em 512, os modelos professores da família VGG demonstraram uma dinâmica de otimização atípica durante o treinamento. A curva da acurácia de validação em função das épocas se mostrou bastante acidentada, exibindo flutuações abruptas que contrastaram com as curvas observadas nas famílias ResNet e ConvNeXt. Esse fenômeno indica uma sensibilidade latente dos mapas de características puramente sequenciais da VGG frente à magnitude do gradiente da camada linear. Para investigações subsequentes, fica evidente a necessidade de explorar outros hiperparâmetros, como passos de aprendizado (*learning rates*) mais conservadores e decay escalonados, especificamente para o tratamento desta família.




Figura 3: Acurácia da VGG-11 com batch de 512 (cifar 100)

3. **Retardo de Convergência no Regime de Destilação:** Identificou-se uma assimetria temporal na velocidade de convergência entre as duas fases do pipeline. Enquanto os classificadores lineares dos professores convergiam rapidamente para os seus respectivos limites de generalização de validação (comumente antes da vigésima (20^a) época de treino), os modelos estudantes mostraram um ritmo significativamente mais lento de convergência. Mesmo após 100 épocas, a curva de aprendizado dos estudantes ainda dava sinais de estar em crescimento. Esse atraso realça a barreira envolvida no alinhamento de *manifolds* latentes via erro quadrático médio (MSE), evidenciando que redes compactas demandam regimes de treinamento estendidos para internalizar por completo a topologia projetada pelo professor.



Figura 4: Acurácia da MobileNet treinada na VGG-19 (cifar 100)

Tabela 1: Resumo Comparativo de Acurácia de Teste: Modelos Professores versus Estudantes Destilados

Dataset	Modelo Prof.	Acurácia	MobileNetV2		ShuffleNetV2	
			Acurácia	(Est/Prof)	Acurácia	(Est/Prof)
CIFAR-100	VGG-11-BN	62	43	0,69	37	0,60
	VGG-16-BN	59	43	0,74	36	0,61
	VGG-19-BN	57	43	0,75	39	0,68
	ResNet-18	58	52	0,90	44	0,76
	ResNet-50	58	48	0,83	40	0,68
	ResNet-101	63	46	0,74	40	0,64
	ConvNeXt-Tiny	79	44	0,55	36	0,46
	ConvNeXt-Small	81	44	0,54	36	0,45
	ConvNeXt-Base	81	44	0,55	38	0,47
	ConvNeXt-Large	82	46	0,56	41	0,49
Intel Scenes	VGG-11-BN	92	67	0,73	70	0,76
	VGG-16-BN	91	68	0,75	66	0,73
	VGG-19-BN	92	79	0,86	77	0,84
	ResNet-18	91	83	0,92	81	0,89
	ResNet-50	91	80	0,88	75	0,83
	ResNet-101	91	80	0,88	77	0,84
	ConvNeXt-Tiny	94	78	0,83	77	0,82
	ConvNeXt-Small	94	80	0,85	76	0,81
	ConvNeXt-Base	94	79	0,84	76	0,81
	ConvNeXt-Large	94	80	0,86	79	0,84

4 Resultados Quantitativos e Análise Científica

Após a conclusão das fases de treinamento e destilação, foi feita a testagem de todos os modelos (professores e estudantes) nos conjuntos de testes previamente separados (intocados nas fases anteriores) para coleta dos dados de acurácia definitivos. Os principais resultados do experimento estão descritos na Tabela 1. Abaixo, detalham-se as análises teóricas fundamentadas para cada um dos padrões identificados.

4.1 Divergência de Desempenho dos Professores

A análise inicial da Tabela 1 revela um comportamento heterogêneo entre as famílias de modelos professores. No conjunto de dados CIFAR-100, observa-se uma degradação na acurácia da família VGG à medida que a capacidade do modelo aumenta, com a VGG-11-BN atingindo 62% e a VGG-19-BN decaindo para 57%. Em contrapartida, a família ConvNeXt exibe o comportamento esperado de escalabilidade, expandindo sua acurácia de 79% (Tiny) para 82% (Large).

Essa divergência pode ser explicada pela natureza das arquiteturas dos modelos. Redes excessivamente profundas e desprovidas de conexões residuais, como a VGG-19, tendem a sofrer de hiper-especialização nos componentes semânticos do mapeamento de origem (ImageNet) em suas camadas terminais. Consequentemente, suas características perdem generalização para domínios distintos ([Yosinski et al. 2014]). Por outro lado, as conexões de atalho (*skip-connections*) presentes nas arquiteturas ResNet e ConvNeXt atuam como vias de preservação de gradiente e de atributos estruturais de baixo e médio nível, garantindo que mesmo os modelos de grande porte mantenham uma base de características altamente transferível ([Veit, Wilber e Belongie 2016]). Esse fenômeno foi observado por [Kornblith, Shlens e Le 2019].

4.2 Saturação de Manifolds

No cenário do dataset Intel Scenes, constata-se uma estagnação generalizada na acurácia de todos os professores, a qual fixa-se estritamente na faixa entre 91% e 94%, independentemente da escala paramétrica. Esse fenômeno evidencia a *saturação de manifold* em tarefas de baixa complexidade conceitual. Sendo um dataset composto por poucas classes latentes e padrões visuais linearmente bem definidos, o espaço de características produzido mesmo por um extrator compacto (VGG-11-BN) já provê separabilidade linear quase ótima. Portanto, o incremento na capacidade dos professores torna-se redundante para a tarefa de classificação linear propriamente dita.

4.3 O Paradoxo do Professor Perfeito e o Gargalo de Capacidade

Um dos achados mais contra-intuitivos deste estudo reside no fato de que o aumento do desempenho absoluto do modelo professor não induz uma melhoria correspondente no modelo estudante destilado. No CIFAR-100, o professor mais robusto (ConvNeXt-Large, 82%) gerou um estudante MobileNetV2 de apenas 46%. Paradoxalmente, o melhor desempenho absoluto entre os estudantes em ambos os datasets foi obtido utilizando a *ResNet-18* como professora (52% no CIFAR-100 e 83% no Intel Scenes), apesar de esta figurar como um dos professores de menor acurácia nominal (58% e 91%, respectivamente).

Esse comportamento valida empiricamente as hipóteses de descompasso de capacidade (*capacity mismatch*) de [Mirzadeh et al. 2020] e estrangulamento geométrico de posto (*rankbottleneck*). A ResNet-18 projeta um espaço latente *post-GAP* de 512 dimensões, enquanto modelos como ResNet-101 e a família ConvNeXt operam em espaços hiper-dimensionais de 1024 a 2048 dimensões, caracterizados por topologias complexas e manifolds de alto posto (*high-rank*).

Quando arquiteturas compactas como MobileNetV2 e ShuffleNetV2 tentam mimetizar esses espaços complexos via regressão por Erro Quadrático Médio (MSE), o módulo projetor de múltiplas camadas falha em mapear fielmente a alta variância geométrica do professor devido à escassez de parâmetros do estudante ([Heo et al. 2019]). A MSE força o estudante de baixa capacidade a convergir para uma média “borrada” da distribuição do professor, resultando no colapso do aprendizado ([Tian, Krishnan e Isola 2019]). A ResNet-18, por apresentar um manifold geometricamente mais simples, oferece um alvo de destilação alcançável para os estudantes, mitigando o efeito do estrangulamento de capacidade.

4.4 Análise Crítica da Razão Estudante-Professor e a Ilusão de Eficiência

A métrica de razão de acurácia (Est/Prof) foi usada como um indicador da eficiência intrínseca da transferência de conhecimento. Contudo, os dados obtidos revelam que essa métrica pode induzir a uma falsa percepção de otimização. Na família VGG aplicada ao CIFAR-100, a razão cresce de forma incremental ($0,69 \rightarrow 0,74 \rightarrow 0,75$) conforme a rede se aprofunda.

Uma análise rigorosa demonstra que esse crescimento é puramente um artefato matemático decorrente da degradação do denominador (acurácia do professor), visto que a acurácia absoluta da MobileNetV2 permanece estagnada em exatamente 43%. O estudante falha em absorver qualquer nuance adicional das VGGs mais profundas. Inversamente, na família ResNet, a razão decresce conforme o modelo expande, refletindo o agravamento do *capacity mismatch* discutido anteriormente, onde a acurácia do estudante declina ativamente ($52\% \rightarrow 48\% \rightarrow 46\%$) enquanto o professor expande ou mantém sua capacidade de generalização.

4.5 Influência da Topologia do Estudante: Alinhamento Arquitetural

A avaliação comparativa entre os modelos de borda demonstra uma dominância consistente da MobileNetV2 sobre a ShuffleNetV2 em praticamente todas as configurações experimentais. A MobileNetV2 estabelece de forma sistemática acurácias superiores e melhores taxas de transferência adaptativa.

Propõe-se que essa discrepância decorre do nível de *alinhamento arquitetural* entre os pares professor-estudante. A MobileNetV2 baseia-se em convoluções separáveis em profundidade estruturadas em blocos residuais invertidos (*inverted residuals*) e gargalos lineares. Essa formulação possui forte afinidade matemática e topológica com os blocos residuais das ResNets e os blocos de convolução modernos das ConvNeXts (que herdaram os princípios de gargalo invertido). Essa similaridade estrutural suaviza a paisagem de perda (*loss landscape*) durante o alinhamento de características por MSE. Por outro lado, a ShuffleNetV2 opera sob esquemas de divisão e permutação de canais (*channel splitting* e *shuffling*), gerando representações latentes espacial e logicamente fragmentadas que amplificam o erro de aproximação do projetor linear e reduzem a eficácia da destilação baseada em características.

4.6 A Anomalia Representacional da VGG-19

Por fim, destaca-se um fenômeno singular dos estudantes da VGG-19: enquanto os estudantes destilados a partir da VGG-11-BN e VGG-16-BN mantiveram-se estagnados em patamares inferiores (67%–70%), a destilação baseada na VGG-19-BN provocou um salto abrupto na acurácia de ambos os estudantes, elevando a MobileNetV2 para 79% e a ShuffleNetV2 para 77%. É imperativo notar que a acurácia do professor permaneceu virtualmente inalterada (92%).

Como o backbone do professor operou de forma estritamente congelada, esse salto indica que a profundidade específica da VGG-19-BN gerou, de forma colateral, um espaço latente *post-GAP*

geometricamente favorável para problemas de baixa dimensionalidade. Hipotetiza-se que a contração sofrida pelas representações devido ao excesso de camadas lineares na VGG-19 reduziu o posto efetivo do seu manifold, concentrando as características em agrupamentos de baixa variância, permitindo que os estudantes aproximassem o espaço latente de forma mais eficiente.

5 Conclusões e Propostas de Melhoria

Este trabalho investigou a dinâmica da Destilação de Conhecimento Baseada em Características (*Feature-based KD*) em dispositivos de borda, mapeando as representações *post-GAP* de grandes extratores congelados para redes compactas. Os resultados obtidos expuseram as complexidades subjacentes à transferência de aprendizado linear e desafiaram a premissa de que a maximização da capacidade do professor garante um estudante mais preciso.

Em resposta à principal indagação empírica deste estudo - qual professor transfere melhor o conhecimento? - conclui-se de forma contundente que a ResNet-18 figura como a arquitetura mais eficiente. Apesar de possuir acurácias nominais inferiores a modelos da família ConvNeXt ou ResNets mais profundas, a ResNet-18 projeta um espaço latente de dimensionalidade moderada (512 dimensões) e menor variância geométrica. Essa característica mitiga o estrangulamento de posto (*rank bottleneck*) e evita o colapso de aprendizado no estudante. Professores excessivamente complexos geraram descompasso de capacidade (*capacity mismatch*), resultando nos piores desempenhos de transferência observados no CIFAR-100.

No que tange à melhor arquitetura para o módulo estudante (encoder + predictor), os dados apontam a MobileNetV2 como a escolha superior. A sua estrutura baseada em blocos residuais invertidos apresenta um forte alinhamento topológico com as características extraídas por ResNets e ConvNeXts. Essa afinidade arquitetural suavizou a otimização em relação à ShuffleNetV2, permitindo uma economia substancial de parâmetros e GFLOPS sem sacrificar a taxa de transferência de conhecimento de forma tão acentuada.

Por fim, quanto à **formulação da função de perda (*loss function*)**, o estudo adotou uma abordagem híbrida, combinando o Erro Quadrático Médio (MSE) do projetor latente com a Entropia Cruzada (*Cross-Entropy*) do classificador congelado. Contudo, os resultados demonstraram que o sinal de gradiente supervisionado da Entropia Cruzada foi insuficiente para contornar o colapso de aprendizado induzido pela penalidade L_2 estrita em cenários de alta disparidade de capacidade.

5.1 Propostas de Melhoria e Trabalhos Futuros

Apesar das constatações relevantes, a modelagem atual possui limitações que abrem caminhos para a evolução.

- **Alvo da Predição e Granularidade Espacial:** O presente estudo forçou o estudante a prever o vetor condensado *post-GAP* (C -dimensional) do professor. Embora essa abordagem reduza a carga computacional, a operação de agrupamento global (*Global Average Pooling*) destrói informações espaciais críticas. Como proposta de melhoria, trabalhos futuros devem investigar a destilação baseada em mapas de características *pre-GAP* (ex: tensores $7 \times 7 \times C$). Para isso, o projetor linear do estudante deverá ser substituído por blocos convolucionais adaptativos (1×1 seguidos de 3×3), capazes de alinhar os canais e preservar a semântica espacial das ativações do professor.
- **Uso de Aprendizado Contrastivo:** Uma vez observado que a regressão direta (MSE) atua como um gargalo destrutivo quando a capacidade do estudante é diminuta, propõe-se a substituição do alinhamento geométrico por métodos de Destilação Contrastiva (como

Contrastive Representation Distillation, de [Tian, Krishnan e Isola 2019]). O uso de perdas contrastivas em vez de L_2 relaxará a restrição de correspondência exata um-para-um dos tensores, forçando o estudante apenas a maximizar a informação mútua com o professor. Isso permitirá que o modelo compacto estruture seu próprio *manifold* de forma independente e adequada à sua capacidade paramétrica.

- **Uso de Destilação Relacional:** adotar esquemas de Destilação de Conhecimento Relacional (RKD), conforme proposto por Park et al. [Park et al. 2019]. Ao invés de forçar o modelo compacto a imitar coordenadas latentes absolutas, o esquema RKD minimiza a divergência das relações métricas e angulares entre diferentes instâncias dentro de um mesmo lote (*batch*). Essa transição estrutural permite que o estudante preserve as distâncias inter-classes aprendidas pelo professor gigante no ImageNet, mas lhe garante a flexibilidade geométrica necessária para construir seu próprio *manifold* de forma compatível com suas restrições paramétricas.
- **Expansão do Espaço Latente e *Projector Ensemble*:** Durante a regressão baseada em características, os mapas de ativação do estudante foram forçados através de uma camada oculta fixada rigidamente em 512 dimensões antes de serem expandidos para igualar o espaço do professor (que atinge 2048 dimensões em modelos como ConvNeXt-Large).

Essa formulação atua, na prática, como um gargalo de informações (*information bottleneck*). Qualquer característica ortogonal ou variância de alta dimensionalidade do professor que exceda o posto restrito a 512 é comprimida e destruída, prejudicando a aprendizagem.

Para mitigar essa falha mecânica, propõe-se a reformulação do projetor mediante duas frentes:

- **Expansão de Dimensionalidade Não-Restritiva:** A primeira e mais direta correção consiste em abolir a compressão na camada oculta do *multilayer perceptron* (MLP). A topologia deve ser dinamicamente ajustada para garantir uma dimensionalidade interna expansiva, satisfazendo a restrição de que a camada oculta H seja maior ou igual à dimensão máxima envolvida, isto é, $H \geq \max(D_{\text{estudante}}, D_{\text{professor}})$. Essa expansão paramétrica assegura que a transformação afim intermediária possua graus de liberdade suficientes para evitar o estrangulamento de posto.
- **Implementação de um *Projector Ensemble*:** Consiste na adoção de um Conjunto de Projetores (*Projector Ensemble*). Conforme demonstrado por [Chen et al. 2022], forçar o mapeamento latente através de um único projetor linear reduz a eficácia do alinhamento. Ao instanciar múltiplos projetores paralelos e independentes, e computar a divergência média gerada por todos eles, cria-se um fluxo de gradiente redundante e diversificado. Essa técnica alarga a "banda de transmissão" de conhecimento, superando o gargalo de representação.

Disponibilidade de Código e Dados

Visando garantir a reprodutibilidade integral dos experimentos, todos os códigos-fonte, *scripts* de treinamento distribuído, módulos de avaliação e arquivos auxiliares desenvolvidos para este projeto foram disponibilizados publicamente. O repositório completo pode ser acessado na plataforma GitHub através do seguinte endereço: <https://github.com/Attilio0/feature-based-knowledge-distillation.git>.

Referências

- [Chen et al. 2022]CHEN, Y. et al. Improved feature distillation via projector ensemble. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2022. v. 35, p. 28146–28159.
- [He et al. 2016]HE, K. et al. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2016. p. 770–778.
- [Heo et al. 2019]HEO, B. et al. A comprehensive overhaul of feature distillation. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. [S.l.: s.n.], 2019. p. 1921–1930.
- [Hinton, Vinyals e Dean 2015]HINTON, G.; VINYALS, O.; DEAN, J. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.
- [Kornblith, Shlens e Le 2019]KORNBLITH, S.; SHLENS, J.; LE, Q. V. Do better imagenet models transfer better? In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. [S.l.: s.n.], 2019. p. 2661–2671.
- [Liu et al. 2022]LIU, Z. et al. A convnet for the 2020s. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2022. p. 11966–11976.
- [Mirzadeh et al. 2020]MIRZADEH, S. I. et al. Improved knowledge distillation via teacher assistant. In: *Proceedings of the AAAI conference on artificial intelligence*. [S.l.: s.n.], 2020. v. 34, n. 04, p. 5191–5198.
- [Park et al. 2019]PARK, W. et al. Relational knowledge distillation. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2019. p. 3967–3976.
- [Romero et al. 2014]ROMERO, A. et al. Fitnets: Hints for thin deep nets. *arXiv preprint arXiv:1412.6550*, 2014.
- [Simonyan e Zisserman 2014]SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014.
- [Tian, Krishnan e Isola 2019]TIAN, Y.; KRISHNAN, D.; ISOLA, P. Contrastive representation distillation. In: *International Conference on Learning Representations*. [S.l.: s.n.], 2019.
- [Veit, Wilber e Belongie 2016]VEIT, A.; WILBER, M. J.; BELONGIE, S. Residual networks behave like ensembles of relatively shallow networks. In: *Advances in neural information processing systems*. [S.l.: s.n.], 2016. v. 29.
- [Yosinski et al. 2014]YOSINSKI, J. et al. How transferable are features in deep neural networks? In: *Advances in neural information processing systems*. [S.l.: s.n.], 2014. v. 27.